

BioPHP — Analyse complète du dossier Legacy et état de la refonte

Date de synthèse : 2026-08-12 — **mis à jour le 2026-08-13** Fait suite à : [legacy_refacto_memo.md](#) (2026-08-11), dont ce document corrige et approfondit plusieurs affirmations trop optimistes.

Mise à jour du 13 août 2026 : quatre des parseurs listés ci-dessous comme ABSENTS ont été portés (EMBL, PDB, PROSITE, ExPASy ENZYME) — voir [compte_rendu_maj_2026-08-13.md](#) pour le détail de cette session. Les sections suivantes ont été corrigées en conséquence ; le texte narratif d'origine (rédigé le 12) est conservé tel quel là où il reste exact.

Contexte

BioPHP est une librairie PHP de bioinformatique historiquement écrite en style procédural mono-fichier (dossier `Legacy/`), en cours de refonte vers une architecture orientée services Symfony (`Domain/`, `Api/`). La veille de cette analyse (2026-08-11), une session de maintenance a modernisé les dépendances du projet (PHP 7.2 → 8.1, Symfony 4 → 6.4, PHPUnit 7.5 → 8.5, retrait des paquets abandonnés, migration des entités Doctrine vers les attributs PHP natifs). Cette modernisation a porté uniquement sur l'infrastructure (composer.json, tests API, mapping Doctrine) et n'a touché ni le contenu du dossier `Legacy/`, ni l'avancement du portage fonctionnel. Voir `docs/compte_rendu_maj_2026-08-11.md` et sa partie 2 pour le détail de cette session.

Le memo existant (`legacy_refacto_memo.md`) donne une table de correspondance Legacy → refonte, mais s'avère **globalement optimiste** : il affirme par exemple que `genome.inc.php`, `kegg.inc.php` (1672 lignes), `unigene.inc.php` et `transfac.inc.php` (732 lignes) sont couverts par des `Parse*Manager`, alors qu'en réalité **aucun de ces quatre fichiers n'a d'équivalent** dans la refonte :

`Domain/Database/Factory/DatabaseReaderFactory.php` ne reconnaît que les formats `"GENBANK"` et `"SWISSPROT"`, tout le reste levant une exception `Unknown database format !`.

Ce document remplace le memo précédent comme référence : chacun des 26 fichiers `Legacy/*.php` a été lu intégralement et chaque correspondance annoncée vérifiée en lisant le fichier de la refonte concerné, pas seulement son nom.

Bilan chiffré

(Chiffres du 12 août ; voir l'encart de mise à jour ci-dessus pour l'évolution au 13 août.)

Sur 11 223 lignes de code Legacy, environ **4 386 lignes** ont un équivalent réel et vérifié dans la refonte (`seq.php`, `seqalign.php`, `seqdb.php`, `resten.php`, une partie d' `etc.php`), soit **≈ 39 % du volume** — concentré exclusivement sur le noyau séquence / alignement / GenBank-Swissprot / restriction enzymes.

Les **≈ 61 % restants** — la totalité des 19 parseurs de bases de données externes tierces (aaindex, blocks, embl, entrez, epd, expasy, genome, hgbase, kegg, lit, motif, pdb, pdbstr, pir, pmd, prf, prints, prodom, transfac, unigene) — sont **purement et simplement absents** de la refonte à ce jour.

Statut	Fichiers	Lignes
COMPLET	seq.php, seqalign.php, seqdb.php, resten.php	4 179
PARTIEL	etc.php, refseq.inc.php (doublon de seqalign.php)	479
ABSENT	19 parseurs de bases externes + entrez.inc.php (doublon interne)	≈ 6 554
OBSOLÈTE (superséde par Tests/)	test.php	11

Au 13 août 2026 : embl.inc.php, pdb.inc.php, motif.inc.php et expasy.inc.php (211 + 1845 + 288 + 215 = 2 559 lignes) sortent de la catégorie ABSENT. Il reste **15** parseurs de bases externes non portés (au lieu de 19), pour ≈ 3 995 lignes Legacy restantes dans cette catégorie. Le statut de ces 4 fichiers est nuancé : la refonte cible les champs réellement utiles (voir la table de correspondance ci-dessous et le détail par fichier plus bas), pas une reproduction ligne à ligne du Legacy — qui, pour PDB et PROSITE notamment, était lui-même inachevé sur une bonne partie de son contenu.

Forces générales du Legacy

- **Couverture fonctionnelle très large à l'origine** : 20 formats de bases biologiques différents étaient parsés (GenBank, Swissprot, EMBL, PDB, KEGG, TRANSFAC, PIR, PRF, PMD, PROSITE, PRINTS, ProDom, BLOCKS, AAINDEX, EPD, ExPASy ENZYME, HGBase, UniGene, "DOGS" genome, littérature NCBI). Au 12 août, la refonte n'en couvrait que 2 (GenBank, Swissprot) ; au 13 août, 6 (+ EMBL, PDB, PROSITE, ExPASy ENZYME — voir l'encart de mise à jour en tête de document).
- **Logique métier de séquence robuste et éprouvée** (seq.php , seqalign.php , etc.php , resten.php) : ce noyau, utilisé pendant des années sur des données réelles, est justement celui qui a été le mieux et le plus fidèlement porté.
- **Documentation inline dense** : presque chaque fonction Legacy est accompagnée d'un exemple concret de ligne de données réelle — ce style a globalement été conservé dans la refonte.

Faiblesses générales du Legacy

- Style procédural avec classes « à l'ancienne » (constructeur `function NomDeLaClasse()`), aucun typage, propriétés publiques par défaut (`var $x`).
- Usage systématique d' `each()` pour itérer les tableaux de lignes — **fonction supprimée depuis PHP 8.0** : aucun des 26 fichiers Legacy ne s'exécuterait tel quel sous PHP 8.1, la cible actuelle du projet.
- Usage de fonctions POSIX regex obsolètes (`ereg_replace` , `ereg_replace` , supprimées depuis PHP 7.0) dans `etc.php` , `hgbase.inc.php` , `seq.php` .
- Aucun test automatisé (`test.php` n'en est pas un — script exploratoire sans assertion).

- Couplage fort au système de fichiers (`fopen` / `fseek` / positions d'octets fixes) et aux variables globales (`$GLOBALS` , `global $RestEn_DB` , `global $chemgrp_matrix`).
- Fonctionnalités **annoncées mais jamais finies dans le Legacy lui-même** : blocs `if` vides dans `hgbase.inc.php` et `prf.inc.php` , propriétés jamais renseignées dans `pmd.inc.php` , fonctions vides dans `kegg.inc.php` (`parse_mol_kegg` , `parse_ligand_kegg`).
- Usage risqué d' `eval()` dans `entrez.inc.php` pour dispatcher dynamiquement des sous-parseurs.

Table de correspondance complète

Fichier Legacy	Lignes	Statut	Fichier(s) refonte concerné(s)
<code>aaindex.inc.php</code>	83	ABSENT	—
<code>blocks.inc.php</code>	84	ABSENT	—
<code>embl.inc.php</code>	211	COMPLET (<i>dépasse le stub Legacy, resté inachevé</i>)	<code>ParseEmblManager.php</code>
<code>entrez.inc.php</code>	373	ABSENT (<i>doublon interne de seqdb.php</i>)	couvert par ricochet via <code>ParseGenbankManager.php</code>
<code>epd.inc.php</code>	232	ABSENT	—
<code>etc.php</code>	335	PARTIEL	<code>SequenceMatchManager.php</code> , <code>FormatsTrait.php</code>
<code>expasy.inc.php</code>	215	COMPLET	<code>ParseExpasyEnzymeManager.php</code>
<code>genome.inc.php</code>	294	ABSENT	—
<code>hgbase.inc.php</code>	159	ABSENT	—
<code>kegg.inc.php</code>	1672	ABSENT	—
<code>lit.inc.php</code>	138	ABSENT	—
<code>motif.inc.php</code>	288	PARTIEL (<i>champ MA/matrice gardé en texte brut</i>)	<code>ParsePrositeManager.php</code>
<code>pdb.inc.php</code>	1845	PARTIEL (<i>champs structuraux et atomiques courants seulement</i>)	<code>ParsePdbManager.php</code>
<code>pdbsr.inc.php</code>	56	ABSENT	—
<code>pir.inc.php</code>	320	ABSENT	—
<code>pmd.inc.php</code>	150	ABSENT	—
<code>prf.inc.php</code>	229	ABSENT	—
<code>prints.inc.php</code>	77	ABSENT	—
<code>prodom.inc.php</code>	118	ABSENT	—

Fichier Legacy	Lignes	Statut	Fichier(s) refonte concerné(s)
refseq.inc.php	144	PARTIEL (<i>nom trompeur, contenu réel = doublon de seqalign.php</i>)	SequenceAlignmentManager.php
resten.php	795	COMPLET (1 bug trouvé)	RestrictionEnzymeManager.php, TypeIIEndonucleaseApi.php, Entity/Enzyme.php
seq.php	937	COMPLET (1 bug auto-documenté)	SequenceManager.php, ProteinManager.php
seqalign.php	548	COMPLET	SequenceAlignmentManager.php
seqdb.php	1099	COMPLET (<i>GenBank + Swissprot uniquement</i>)	DatabaseManager.php, ParseGenbankManager.php, ParseSwissprotManager.php
test.php	11	OBSOLÈTE	Tests/*.php (61 fichiers)
transfac.inc.php	732	ABSENT	—
unigene.inc.php	78	ABSENT	—

Fiches détaillées par fichier

Noyau métier — portage COMPLET

seq.php (937 l.) — Cœur historique : `complement()`, `revcomp()`, `halfstr()`, `get_bridge()`, `expand_na()` (codes IUPAC → regex), classe `protein::molwt()`, classe `seq` géante (`molwt`, `count_codons`, `subseq`, `patpos` / `patfreq` / `findpattern`, `symfreq`, `translate`, `charge`, `chemgrp`, `is_mirror` / `is_palindrome`). Porté vers `SequenceManager.php` de façon quasi 1:1, avec externalisation pertinente des tables codées en dur (poids atomiques, table des codons) via des adapters API. **Point faible refonte** : `SequenceManager::getBridge()` porte encore le commentaire `@todo : Correct it – does not seems to work :/` de l'autrice — bug connu non corrigé. **Point faible Legacy** : la classe `seq` cumulait déjà plus de 20 responsabilités (God Object), défaut hérité tel quel par `SequenceManager`.

seqalign.php (548 l.) — Classe `SeqAlign` : alignements multi-séquences FASTA/CLUSTAL, navigation, statistiques, conversion colonne↔résidu, consensus. Porté fidèlement vers `SequenceAlignmentManager.php`, avec une vraie amélioration : les pointeurs manuels `seqptr` / `first()` / `next()` sont remplacés par un `\ArrayIterator` natif PHP. **Point faible commun** : `resVar()` / `consensus()` recalculent en $O(n \times m)$ à chaque appel, sans mémorisation, dans le Legacy comme dans la refonte.

seqdb.php (1099 l.) — Moteur de base Legacy : `process_ft`, `get_entryid`, `line2r`, `bsrch_tabfile` (recherche dichotomique sur fichier `.IDX`), classe `SeqDB::fetch()`, et les deux parseurs `parse_swissprot()` et `parse_id()` (GenBank). Porté vers `DatabaseManager.php` + `DatabaseReaderFactory` / `DatabaseRecorderFactory` + `ParseGenbankManager.php` + `ParseSwissprotManager.php`, avec une amélioration architecturale nette : le mécanisme de fichiers `.IDX` / `.DIR` bas niveau est remplacé par une indexation Doctrine (`Collection`, `CollectionElement`).

Limite : ne couvre que GenBank et Swissprot, pas les 19 autres formats externes que g rait le Legacy dans son ensemble.

resten.php (795 l.) — Base de ~620 enzymes de restriction cod es en dur, classe `RestEn` (`CutSeq` , `FindRestEn` , `GetPattern` , `GetCutPos`). Meilleur portage du d p t : `RestrictionEnzymeManager.php` reproduit chaque m thode fid lement, et remplace la base cod e en dur par un appel HTTP via `TypeIIEndonucleaseApi` (bonne modernisation). **Bug trouv  dans la refonte** : `RestrictionEnzymeManager::fetchCutposAndPlen()` r f rence une variable `$RestEn_List[]` qui n'existe pas dans la m thode (c'est `$aEnzymes` qui est utilis  et retourn  partout ailleurs) — la m thode renvoie donc **toujours un tableau vide**, r gression silencieuse par rapport au Legacy.

Cas particuliers — noms trompeurs

entrez.inc.php (373 l.) ne contacte pas Entrez : c'est un parseur GenBank-like quasi identique   `parse_id()` de `seqdb.php` , avec en plus un `eval()` dangereux pour dispatcher les sous-parseurs. Fonctionnellement redondant avec `seqdb.php` , donc son absence de portage d di  n'est pas une perte r elle.

refseq.inc.php (144 l.) ne parse pas RefSeq : il contient uniquement le constructeur de `SeqAlign()` (lecture FASTA/CLUSTAL), copi -coll  exact des lignes 407-548 de `seqalign.php` . Son contenu r el est donc d j  couvert par `SequenceAlignmentManager` , mais aucun vrai parseur RefSeq (`dbVar`, `accessions NM_/NP_/NR_`) n'a jamais exist , ni dans le Legacy ni dans la refonte.

genome.inc.php (294 l.), malgr  son nom proche d' `entrez.inc.php` , est un format enti rement diff rent (« DOGS » — statistiques de s quen age par organisme), sans lien avec `kegg.inc.php` qui contient lui aussi une classe `Genome` (KEGG). Trois notions distinctes partagent un vocabulaire proche, source de confusion   lever dans toute future refonte.

Parseurs de bases externes — ABSENTS de la refonte

(Liste d'origine au 12 ao t ; `embl.inc.php`, `pdb.inc.php`, `motif.inc.php` et `expasy.inc.php` en ont  t  retir s le 13 ao t, port s depuis — voir « Parseurs port s le 13 ao t 2026 » plus bas.)

Quinze fichiers, tous des parseurs de formats plats propres   une base de donn es biologique externe, n'ont **aucun  quivalent** dans `Domain/` ni `Api/` :

Fichier	Lignes	Base cibl�e	Point notable
kegg.inc.php	1672	KEGG (voies m�taboliques)	Fichier le plus riche fonctionnellement (6 classes) ; <code>parse_mol_kegg</code> / <code>parse_ligand_kegg</code> rest�es vides m�me dans le Legacy
transfac.inc.php	732	TRANSFAC (facteurs de transcription)	5 sous-parseurs homog�nes, dupliquant le m�me bloc de gestion des dates
pir.inc.php	320	PIR (Protein Information	Pattern <code>#cl� valeur</code> bien factoris� sur 4 champs

Fichier	Lignes	Base ciblée	Point notable
		Resource)	
genome.inc.php	294	« DOGS » (statistiques de séquençage)	Bug ligne 161 : <code>\$in_ref_flag == TRUE;</code> (comparaison au lieu d'affectation)
prf.inc.php	229	PRF/NBRF	Champs SOURCE/KEYWORD/CROSSREF/SEQUENCE jamais implémentés
epd.inc.php	232	EPD (promoteurs eucaryotes)	Copié-collé de la structure d'embl.inc.php, variables mortes
pmd.inc.php	150	PMD (Protein Mutant Database)	Moitié de la classe jamais renseignée, même dans le Legacy d'origine
hgbase.inc.php	159	HGBase (mutations humaines)	Champs ALLELE/ISINBLOCK avec blocs <code>if</code> vides
lit.inc.php	138	Revue biomédicales NCBI	Format le plus simple ; seconde moitié du fichier commentée (code mort)
prodom.inc.php	118	ProDom (domaines protéiques)	Exemple de données réel inclus en commentaire
aaindex.inc.php	83	AAINDEX1 (indices physico-chimiques)	Utilise <code>each()</code> , obsolète depuis PHP 8.0
blocks.inc.php	84	BLOCKS (motifs conservés)	Aucune garde sur les tokens absents
prints.inc.php	77	PRINTS (motifs protéiques)	Seul parseur incapable de traiter plusieurs entrées dans un même flux
unigene.inc.php	78	UniGene (clusters d'ESTs)	En-tête de commentaire encore <code>//pdbstr.inc.php</code> — jamais relu depuis sa création
pdbstr.inc.php	56	Familles structurales PDB dérivées	Plus court et plus simple de tous

Parseurs portés le 13 août 2026

embl.inc.php (211 l.) — Le stub Legacy ne parsait en réalité que ID/AC/DT/SV/DE puis s'arrêtait au premier `//`, sans jamais implémenter OS/OC/RN/FT/SQ malgré les variables déclarées pour ça. Porté vers `ParseEmblManager.php` en suivant l'architecture de `ParseGenbankManager.php` (`\ArrayIterator` + une méthode privée par champ) appliquée aux tags EMBL réels. La table des features (`FT`) est directement analogue à celle de GenBank (même standard INSDC clé/position/qualifiers), la partie où la réutilisation est la plus directe. **Résultat : plus complet que le Legacy dont il est issu.**

pdb.inc.php (1845 l.) — Classe `Protein_PDB` monolithique, une fonction géante de plus de 600 lignes. Un portage 1:1 aurait été disproportionné (nombreux champs jamais renseignés même côté Legacy — `SIGATM` / `MODEL` explicitement marqués « skip for now »). `ParsePdbManager.php` couvre les

enregistrements réellement utiles en bioinformatique structurale (identification, séquence par chaîne via `SEQRES`, structure secondaire `HELIX / SHEET`, maille cristalline `CRYST1`, coordonnées atomiques `ATOM / HETATM`). N'étend pas `ParseDbAbstractManager` : les coordonnées 3D ne correspondent à aucun des champs Sequence/Feature partagés par GenBank/EMBL/Swissprot. Nouveaux objets

`PdbAtom / PdbHelix / PdbSheet` dans `Domain/Model/` (voir encart architecture ci-dessous). **Bug de régression trouvé en l'intégrant** : `DatabaseManager::line2r()` ne savait reconnaître que le terminateur `//` (convention GenBank/EMBL/Swissprot) ; un fichier PDB, qui se termine par `END`, provoquait une boucle infinie jusqu'à épuisement mémoire — corrigé, avec ajout d'une garde de fin de fichier qui manquait entièrement (protège désormais tous les formats contre un fichier tronqué).

motif.inc.php (288 l., PROSITE) — Le Legacy contient un vrai bug (`$lascar = right($linedata, 1)` ; où `$linedata` n'est jamais défini — variable typo pour `$data`, heureusement du code mort puisque `$lascar` n'est ensuite jamais utilisé) et une gestion du champ `MA` (matrice/profil) à 3 niveaux d'imbrication, elle-même fragile. `ParsePrositeManager.php` porte fidèlement tous les autres champs (ID, AC, DT, DE, PA — le motif lui-même —, NR, CC, RU, 3D, DR, DO) et garde `MA` en texte brut plutôt que de reproduire la logique fragile du Legacy. Nouveau `PrositeDbRef.php` dans `Domain/Model/` pour le champ `DR`.

expasy.inc.php (215 l., nomenclature EC) — Port fidèle complet (ID, DE, AN, CA, CF, CC, DI, PR, DR) vers `ParseExpsyEnzymeManager.php`. À ne pas confondre avec `RestrictionEnzymeManager.php`, qui couvre un tout autre Legacy (`resten.php`, enzymes de restriction). Nouveau `ExpasyDisease.php` dans `Domain/Model/` pour le champ `DI`. **Bug trouvé en portant le champ CC** (commentaires multi-lignes) : `file()` conserve déjà le `\n` de fin de ligne de chaque élément du tableau ; le premier jet du code en ajoutait un second par-dessus, doublant les sauts de ligne dans le résultat — corrigé et vérifié empiriquement avant de figer le test.

Nouvelle convention architecturale — `Domain/Model/` : les objets structurés retournés par `ParsePdbManager`, `ParsePrositeManager` et `ParseExpsyEnzymeManager` (atomes PDB, hélices, feuillets, références croisées, maladies associées) n'ont pas leur place parmi les entités Doctrine de `Domain/*/Entity/` (aucune n'est persistée, aucune ne se rattache à une `Sequence` existante), et le terme « DTO » est réservé à la frontière HTTP (`Api/DT0/`). Un premier jet les avait nommées `*DT0` dans `Domain/Database/DT0/` ; après revue, elles ont été renommées et déplacées vers un dossier neutre `Domain/Model/`, sans attribut ORM (donc sans table ni migration associée).

Bugs à corriger en priorité dans la refonte existante

Ces trois points ne relèvent pas d'un nouveau portage mais de la correction de régressions déjà introduites lors de la refonte du noyau pourtant marqué COMPLET :

1. **`RestrictionEnzymeManager::fetchCutposAndPlen()`** — variable `$RestEn_List[]` inexistante à la place de `$aEnzymes` : la méthode renvoie toujours un tableau vide.
2. **`SequenceManager::getBridge()`** — bug auto-documenté par un `@todo` de l'autrice (« does not seems to work »), sans test dédié dans `SequenceManagerTest.php`.
3. **Duplication `complement()` / `revcomp()`** — deux implémentations différentes coexistent (`SequenceManager` via `NucleotidApiAdapter`, et `compDNA()` / `revCompDNA()` dans `SequenceTrait`),

risque de divergence de résultats selon le point d'entrée utilisé.

Feuille de route priorisée

Priorité 1 — corriger les régressions (rapide, fort impact) 1. Corriger

`RestrictionEnzymeManager::fetchCutposAndPlen()` . 2. Corriger `SequenceManager::getBridge()` et ajouter un test dédié. 3. Clarifier/fusionner les deux implémentations de complément/reverse-complement.

Priorité 2 — combler les parseurs externes les plus utiles (effort modéré, indépendants) 4. Fait le

13/08 — `ParseEmblManager.php` + ajout de "EMBL" dans

`DatabaseReaderFactory` / `DatabaseRecorderFactory` — format proche GenBank, portage facilité par réutilisation de `ParseGenbankManager` . 5.  **Fait le 13/08** — Parseur PDB

(`Domain/Database/Service/ParsePdbManager.php` + objets `Domain/Model/Pdb*`) — format externe le plus demandé en bioinformatique structurale, et plus gros trou de couverture. 6.  **Fait le 13/08** — Parseur

PROSITE (`motif.inc.php` → `ParsePrositeManager.php`) — complément naturel des outils de recherche de motifs. 7.  **Fait le 13/08** — Parseur ExpASy ENZYME (`expasy.inc.php` →

`ParseExpasyEnzymeManager.php`) — nomenclature EC, complémentaire des enzymes de restriction déjà couvertes.

Priorité 3 — bases plus spécialisées, à traiter à la demande 8. KEGG (1672 l.) — à décomposer en services distincts (Compound, Enzyme KEGG, Reaction, Ortholog, Genome KEGG) plutôt qu'un portage monolithique. 9. TRANSFAC (732 l.) — 5 sous-parseurs à factoriser, contrairement au Legacy qui duplique le code des dates 5 fois. 10. PIR, PRF, PMD, PRINTS, ProDom, BLOCKS, AAINDEX, EPD, HGBase, UniGene, littérature NCBI, "DOGS" genome — formats plus petits ou moins utilisés, à traiter au cas par cas.

Priorité 4 — dette de tests indépendante du périmètre 11. **Fait le 12/08** — Tests unitaires pour

`DatabaseManager.php` (`DatabaseManagerTest.php` , 5 tests : `fetch()` introuvable/fichier manquant, `recording()` création/réutilisation/ doublon). 12.  **Fait le 12/08** — Tests pour `GeneticsFunctions.php`

et `MathematicsFunctions.php` . En les écrivant, deux cas limites réels ont été mis au jour : `Mean([])` et `Variance()` sur un tableau à un seul élément levaient un `DivisionByZeroError` non intercepté (le

`catch(\Exception $e)` du code ne l'attrape pas, `DivisionByZeroError` héritant de `Error` , pas `Exception`) — corrigé par une garde explicite avec message clair. 13. `GeneticsFunctions` ,

`OligosManager` , `MathematicsFunctions` sont des **ajouts neufs** de la refonte, sans équivalent Legacy — à documenter comme gain net, pas comme dette de portage.

Points de vigilance hérités de la session du 2026-08-11

Rappel des points laissés ouverts par la modernisation des dépendances (non traités dans cette analyse fonctionnelle, mais toujours d'actualité) : - `doctrine/cache` reste un paquet abandonné, non contournable sans passer à `doctrine/orm` 3.x. - `OligosManagerTest::testFindZScore` et `PKApiTest` : deux problèmes préexistants non corrigés. - ~~~ CLAUDE.md décrit encore le projet comme PHP 7.2 / Symfony 4~~~ — mis à jour depuis (le projet cible désormais PHP 8.2+ / Symfony 7, `CLAUDE.md` et `README.md` reflètent cet état).