

Legacy → Refonte

État des lieux complet

Contexte du dossier `Legacy/`, description fichier par fichier, forces et faiblesses, statut réel de portage vérifié ligne à ligne, et feuille de route priorisée pour la suite de la refonte.

26

FICHIERS LEGACY

11 223

LIGNES ANALYSÉES

≈39%

VOLUME PORTÉ

3

BUGS TROUVÉS

Date de synthèse : 12 août 2026

Branche : develop

Fait suite à : docs/legacy_refacto_memo.md (11 août 2026), dont ce rapport corrige plusieurs affirmations trop optimistes après relecture intégrale du code.

Contexte

BioPHP est une librairie PHP de bioinformatique historiquement écrite en style procédural mono-fichier (dossier Legacy/), en cours de refonte vers une architecture orientée services Symfony (Domain/, Api/). La veille de cette analyse (11 août 2026), une session de maintenance a modernisé les dépendances du projet (PHP 7.2 → 8.1, Symfony 4 → 6.4, PHPUnit 7.5 → 8.5, retrait des paquets abandonnés, migration des entités Doctrine vers les attributs PHP natifs). Cette modernisation a porté uniquement sur l'infrastructure et n'a touché ni le contenu du dossier Legacy/, ni l'avancement du portage fonctionnel.

Le memo précédent (legacy_refacto_memo.md) était trop optimiste. Il affirmait que genome.inc.php , kegg.inc.php (1672 lignes), unigene.inc.php et transfac.inc.php (732 lignes) étaient couverts par des Parse*Manager . En réalité, **aucun de ces quatre fichiers n'a d'équivalent** dans la refonte : DatabaseReaderFactory ne reconnaît que les formats GENBANK et SWISSPROT . Ce rapport remplace le memo précédent comme référence : chaque fichier a été relu intégralement et chaque correspondance vérifiée.

Bilan chiffré

Sur 11 223 lignes de code Legacy, environ **4 386 lignes** ont un équivalent réel et vérifié dans la refonte (seq.php , seqalign.php , seqdb.php , resten.php , une partie d' etc.php), soit **≈ 39 % du volume** — concentré exclusivement sur le noyau séquence / alignement / GenBank-Swissprot / restriction enzymes. Les **≈ 61 % restants** — la totalité des 19 parseurs de bases de données externes tierces — sont **purement et simplement absents** de la refonte à ce jour.

Statut	Fichiers	Lignes
COMPLET	seq.php, seqalign.php, seqdb.php, resten.php	4 179
PARTIEL	etc.php, refseq.inc.php (doubleton de seqalign.php)	479
ABSENT	19 parseurs de bases externes + entrez.inc.php (doubleton interne)	≈ 6 554
OBSOLÈTE	test.php (supersède par la suite Tests/)	11

Forces générales du Legacy

- **Couverture fonctionnelle très large à l'origine** : 20 formats de bases biologiques différents parsés (GenBank, Swissprot, EMBL, PDB, KEGG, TRANSFAC, PIR, PRF, PMD, PROSITE, PRINTS, ProDom, BLOCKS, AAINDEX, EPD, ExPASy, HGBase, UniGene, "DOGS" genome, littérature NCBI).

Faiblesses générales du Legacy

- Procédural, classes « à l'ancienne », aucun typage, propriétés publiques par défaut.
- Usage systématique d' each() — **supprimé depuis PHP 8.0** : aucun fichier Legacy ne s'exécute tel quel sous PHP 8.1, la cible actuelle du projet.
- Fonctions POSIX regex obsolètes (eregi_replace) supprimées depuis PHP 7.0.

- **Logique métier de séquence robuste et éprouvée** (seq.php, seqalign.php, etc.php, resten.php) — utilisée pendant des années sur des données réelles, c'est ce noyau qui a été le mieux porté.
- **Documentation inline dense** : presque chaque fonction est accompagnée d'un exemple concret de ligne de données réelle.
- Aucun test automatisé ; couplage fort au système de fichiers et aux variables globales.
- Fonctionnalités annoncées mais jamais finies dans le Legacy lui-même (blocs vides dans hgbase.inc.php, prf.inc.php, kegg.inc.php).
- Usage risqué d' `eval()` dans entrez.inc.php.

Table de correspondance complète

Fichier Legacy	Lignes	Statut	Fichier(s) refonte concerné(s)
aaindex.inc.php	83	ABSENT	—
blocks.inc.php	84	ABSENT	—
embl.inc.php	211	ABSENT	—
entrez.inc.php	373	ABSENT (doublon interne)	couvert par ricochet via ParseGenbankManager.php
epd.inc.php	232	ABSENT	—
etc.php	335	PARTIEL	SequenceMatchManager.php, FormatsTrait.php
expasy.inc.php	215	ABSENT	—
genome.inc.php	294	ABSENT	—
hgbase.inc.php	159	ABSENT	—
kegg.inc.php	1672	ABSENT	—
lit.inc.php	138	ABSENT	—
motif.inc.php	288	ABSENT	—
pdb.inc.php	1845	ABSENT	—
pdbstr.inc.php	56	ABSENT	—
pir.inc.php	320	ABSENT	—
pmd.inc.php	150	ABSENT	—
prf.inc.php	229	ABSENT	—
prints.inc.php	77	ABSENT	—
prodom.inc.php	118	ABSENT	—
refseq.inc.php	144	PARTIEL (nom trompeur)	SequenceAlignmentManager.php
resten.php	795	COMPLET (1 bug)	RestrictionEnzymeManager.php, TypeIIEndonucleaseApi.php, Entity/Enzyme.php
seq.php	937	COMPLET (1 bug)	SequenceManager.php, ProteinManager.php
seqalign.php	548	COMPLET	SequenceAlignmentManager.php
seqdb.php	1099	COMPLET (GenBank+Swissprot)	DatabaseManager.php, ParseGenbankManager.php, ParseSwissprotManager.php

test.php	11	OBSOLÈTE	Tests/*.php (61 fichiers)
transfac.inc.php	732	ABSENT	—
unigene.inc.php	78	ABSENT	—

Fiches détaillées — noyau métier (portage complet)

seq.php – 937 lignes

Cœur historique : `complement()`, `revcomp()`, `halfstr()`, `get_bridge()`, `expand_na()` (codes IUPAC → regex), classe `protein::molwt()`, classe `seq` géante (`molwt`, `count_codons`, `subseq`, `patpos/patfreq/findpattern`, `symfreq`, `translate`, `charge`, `chemgrp`, `is_mirror/is_palindrome`). Porté vers `SequenceManager.php` de façon quasi 1:1, avec externalisation pertinente des tables codées en dur via des adapters API.

- Bug refonte : `SequenceManager::getBridge()` porte encore le `@todo` de l'autrice (« does not seems to work », non corrigé.
- La classe `seq` cumulait déjà 20+ responsabilités (God Object), défaut hérité tel quel.

seqalign.php – 548 lignes

Classe `SeqAlign` : alignements multi-séquences FASTA/CLUSTAL, navigation, statistiques, conversion colonne↔résidu, consensus. Porté fidèlement vers `SequenceAlignmentManager.php`.

- + Les pointeurs manuels `seqptr / first() / next()` sont remplacés par un `\ArrayIterator` natif PHP — une classe de bugs en moins.
- `resVar()` / `consensus()` recalculent en $O(n \times m)$ à chaque appel, sans mémorisation, dans le Legacy comme dans la refonte.

seqdb.php – 1099 lignes

Moteur de base Legacy : `process_ft`, `get_entryid`, `line2r`, `bsrch_tabfile` (recherche dichotomique sur fichier .IDX), classe `SeqDB::fetch()`, parseurs `parse_swissprot()` et `parse_id()` (GenBank). Porté vers `DatabaseManager.php` + factories + `ParseGenbankManager` + `ParseSwissprotManager`.

- + Le mécanisme de fichiers .IDX/.DIR bas niveau est remplacé par une indexation Doctrine (Collection, CollectionElement) — gain de fiabilité net.
- Ne couvre que GenBank et Swissprot, pas les 19 autres formats externes que gérât le Legacy dans son ensemble.

resten.php – 795 lignes

Base de ~620 enzymes de restriction codées en dur, classe `RestEn` (`CutSeq`, `FindRestEn`, `GetPattern`, `GetCutPos`). Meilleur portage du dépôt : `RestrictionEnzymeManager.php` reproduit chaque méthode fidèlement et remplace la base codée en dur par un appel HTTP via `TypeIIEndonucleaseApi`.

- + Base d'enzymes externalisée via API — mise à jour possible sans toucher au code, contrairement au Legacy.
- Bug trouvé : `fetchCutposAndPlen()` référence une variable `$RestEn_List[]` inexistante au lieu de `$aEnzymes` — renvoie toujours un tableau vide.

Cas particuliers — noms trompeurs

entrez.inc.php (373 l.) ne contacte pas Entrez : c'est un parseur GenBank-like quasi identique à `parse_id()` de `seqdb.php`, avec en plus un `eval()` dangereux. Redondant avec `seqdb.php` — son absence de portage dédié n'est pas une perte réelle.

refseq.inc.php (144 l.) ne parse pas RefSeq : il contient uniquement le constructeur de `SeqAlign()`, copié-collé exact des lignes 407-548 de `seqalign.php`. Déjà couvert via `SequenceAlignmentManager`, mais aucun vrai parseur RefSeq n'a jamais existé, ni Legacy ni refonte.

genome.inc.php (294 l.), malgré son nom proche d'`entrez.inc.php`, est un format entièrement différent (« DOGS » — statistiques de séquençage par organisme), sans lien avec la classe `Genome` de `kegg.inc.php`. Trois notions distinctes, vocabulaire proche, source de confusion.

Parseurs de bases externes — absents de la refonte

Dix-neuf fichiers, tous des parseurs de formats plats propres à une base biologique externe, n'ont aucun équivalent dans `Domain/` ni `Api/` :

Fichier	L.	Base ciblée	Point notable
pdb.inc.php	1845	Protein Data Bank (structures 3D)	Plus gros fichier du dépôt ; classe monolithique, une seule fonction géante
kegg.inc.php	1672	KEGG (voies métaboliques)	6 classes ; <code>parse_mol_kegg/parse_ligand_kegg</code> restées vides même dans le Legacy
transfac.inc.php	732	TRANSFAC (facteurs de transcription)	5 sous-parseurs dupliquant le même bloc de gestion des dates
pir.inc.php	320	PIR (Protein Information Resource)	Pattern #clé valeur bien factorisé sur 4 champs
motif.inc.php	288	PROSITE (motifs protéiques)	Parsing à 3 niveaux d'imbrication ; variable utilisée avant définition
genome.inc.php	294	« DOGS » (statistiques de séquençage)	Bug ligne 161 : comparaison au lieu d'affectation
prf.inc.php	229	PRF/NBRF	Champs SOURCE/KEYWORD/CROSSREF/SEQUENCE jamais implémentés
epd.inc.php	232	EPD (promoteurs eucaryotes)	Copié-collé de la structure d' <code>embl.inc.php</code> , variables mortes
expasy.inc.php	215	ExPASy ENZYME (nomenclature EC)	À ne pas confondre avec les enzymes de restriction déjà couvertes
embl.inc.php	211	EMBL (nucléique)	Format proche GenBank — portage le plus facile à mécaniser en priorité
pmd.inc.php	150	PMD (Protein Mutant Database)	Moitié de la classe jamais renseignée, même dans le Legacy d'origine
hgbase.inc.php	159	HGBase (mutations humaines)	Champs ALLELE/ISINBLOCK avec blocs if vides
lit.inc.php	138	Revue biomédicales NCBI	Format le plus simple ; seconde moitié du fichier commentée
prodom.inc.php	118	ProDom (domaines protéiques)	Exemple de données réel inclus en commentaire
aaindex.inc.php	83	AAINDEX1 (indices physico-chimiques)	Utilise <code>each()</code> , obsolète depuis PHP 8.0
blocks.inc.php	84	BLOCKS (motifs conservés)	Aucune garde sur les tokens absents

prints.inc.php	77	PRINTS (motifs protéiques)	Seul parseur incapable de traiter plusieurs entrées dans un même flux
unigene.inc.php	78	UniGene (clusters d'ESTs)	En-tête de commentaire encore "//pdbstr.inc.php" — jamais relu depuis sa création
pdbstr.inc.php	56	Familles structurales PDB dérivées	Plus court et plus simple de tous

Bugs à corriger en priorité dans la refonte existante

Ces trois points ne relèvent pas d'un nouveau portage mais de la correction de régressions déjà introduites lors de la refonte du noyau pourtant marqué COMPLET :

1. **RestrictionEnzymeManager::fetchCutposAndPlen()** — variable `$RestEn_List[]` inexistante à la place de `$aEnzymes` : la méthode renvoie toujours un tableau vide.
2. **SequenceManager::getBridge()** — bug auto-documenté par un `@todo` de l'autrice, sans test dédié dans `SequenceManagerTest.php`.
3. **Duplication complément()/revcomp()** — deux implémentations différentes coexistent (SequenceManager via NucleotidApiAdapter, et compDNA()/revCompDNA() dans SequenceTrait), risque de divergence de résultats selon le point d'entrée utilisé.

Feuille de route priorisée

Priorité 1 — corriger les régressions (rapide, fort impact)

1. Corriger `RestrictionEnzymeManager::fetchCutposAndPlen()`.
2. Corriger `SequenceManager::getBridge()` et ajouter un test dédié.
3. Clarifier/fusionner les deux implémentations de complément/reverse-complement.

Priorité 2 — combler les parseurs externes les plus utiles (effort modéré, indépendants)

4. `ParseEmblManager.php` + ajout de "EMBL" dans les factories — format proche GenBank, portage facilité par réutilisation de `ParseGenbankManager`.
5. Parseur PDB (`Api/PdbApi.php` ou `Domain/Database/Service/ParsePdbManager.php` + DTO) — format externe le plus demandé en bioinformatique structurale, plus gros trou de couverture.
6. Parseur PROSITE (`motif.inc.php`) — complément naturel des outils de recherche de motifs.
7. Parseur ExPASy ENZYME (`expasy.inc.php`) — nomenclature EC, complémentaire des enzymes de restriction déjà couvertes.

Priorité 3 — bases plus spécialisées, à traiter à la demande

8. KEGG (1672 l.) — décomposer en services distincts (Compound, Enzyme KEGG, Reaction, Ortholog, Genome KEGG) plutôt qu'un portage monolithique.
9. TRANSFAC (732 l.) — 5 sous-parseurs à factoriser, contrairement au Legacy qui duplique le code des dates 5 fois.
10. PIR, PRF, PMD, PRINTS, ProDom, BLOCKS, AAINDEX, EPD, HGBase, UniGene, littérature NCBI, "DOGS" genome — formats plus petits ou moins utilisés, à traiter au cas par cas.

Priorité 4 — dette de tests indépendante du périmètre

11. Tests unitaires pour `DatabaseManager.php` (aucun test direct trouvé, seuls `ParseGenbankManagerTest/ParseSwissprotManagerTest` existent).
12. Tests pour `GeneticsFunctions.php` et `MathematicsFunctions.php` (aucun trouvé, contrairement à leur voisin `OligosManager` qui a `OligosManagerTest.php`).
13. `GeneticsFunctions`, `OligosManager`, `MathematicsFunctions` sont des **ajouts neufs** de la refonte, sans équivalent Legacy — à documenter comme gain net, pas comme dette de portage.

Points de vigilance hérités de la session du 11 août 2026 (non traités dans cette analyse fonctionnelle, mais toujours d'actualité) :

- `doctrine/cache` reste un paquet abandonné, non contournable sans passer à `doctrine/orm 3.x`.
- `OligosManagerTest::testFindZScore` et `PKApiTest` : deux problèmes préexistants non corrigés.
- `CLAUDE.md` décrit encore le projet comme PHP 7.2 / Symfony 4 alors que `composer.json` cible désormais PHP 8.1 / Symfony 6.4 — à mettre à jour.