

Du code Legacy à la refonte BioPHP

Inventaire des anciennes fonctionnalités, correspondances dans l'architecture moderne, écarts de comportement et zones non portées.

Conclusion en une phrase

La refonte couvre solidement le noyau de manipulation de séquences, les alignements, la comparaison, les enzymes de restriction et les lecteurs GenBank/Swiss-Prot, mais elle ne remplace pas la majorité des parseurs de bases spécialisées présents dans Legacy/.

27	141	84	46
fichiers Legacy	fonctions Legacy	fichiers PHP refondus	classes de test

Périmètre : comparaison statique de Legacy/ avec Api/, Domain/, DependencyInjection/ et Tests/. Document destiné à la maintenance, à la migration et à la planification de la suite de la refonte.

1. Synthèse exécutive

Le dossier Legacy/ est un assemblage BioPHP historique de fonctions globales, classes à propriétés publiques, données codées en dur et parseurs de formats biologiques. La refonte transforme une partie de ce socle en bundle Symfony 4 : namespaces PSR-4, services injectés, interfaces, DTO d'API, entités Doctrine et tests PHPUnit.

- **Couverture forte** : calculs et recherche sur les séquences, traduction, miroirs/palindromes, protéines, alignements FASTA/CLUSTAL, distances et matrices de substitution, enzymes de restriction.
- **Couverture ciblée** : la gestion de bases locales et les parseurs ont été recentrés sur **GenBank** et **Swiss-Prot**.
- **Rupture majeure** : les parseurs EMBL, KEGG, PDB, TRANSFAC, UniGene, PROSITE, PRINTS, ProDom, BLOCKS, PIR, PRF, PMD, EPD, HGBASE, DOGS et NCBI Literature n'ont pas de successeur dans la refonte.
- **Changement d'architecture** : plusieurs tables embarquées dans le code sont devenues des ressources distantes accessibles via Guzzle et matérialisées en DTO.

À ne pas confondre

Une classe moderne portant un nom voisin n'est pas toujours un remplacement. Par exemple, Domain\Sequence\Entity\Enzyme représente une enzyme de restriction ; elle ne remplace pas le modèle enzymatique KEGG/Expasy avec réactions, substrats, produits et voies.

Méthode et légende

La correspondance repose sur les noms, signatures, commentaires, structures de données et algorithmes visibles dans le dépôt. Aucun ancien scénario d'intégration externe n'a été exécuté. Les statuts sont :

PORTÉ	Successeur explicite avec responsabilité équivalente.
PARTIEL	Capacité conservée avec périmètre, contrat ou accès différent.
NON PORTÉ	Aucun équivalent fonctionnel identifiable dans la refonte.
AJOUT	Capacité moderne sans ancêtre clair dans Legacy/.

Plan de lecture

- Sections 2 à 6 : fonctionnalités effectivement reprises et nouvelles formes d'accès.
- Section 7 : inventaire des parseurs spécialisés abandonnés ou non encore portés.
- Sections 8 à 10 : données externalisées, incompatibilités et feuille de route proposée.

2. Changement de modèle architectural

Axe	Legacy	Refonte	Statut
Chargement	require_once et fichiers .inc.php	Autoload PSR-4 Amelaye\BioPHP\	PORTÉ
Organisation	Fonctions globales et classes monolithiques	Entités, services, builders, interfaces, traits et factories	PORTÉ
État	Propriétés publiques var et tableaux globaux	Propriétés privées, accesseurs typés, injection de dépendances	PORTÉ
Données de référence	Tableaux codés en dur dans seq.php/resten.php	Adaptateurs HTTP, DTO et API BioPHP	PARTIEL
Persistance	Fichiers .idx/.dir et pointeurs de fichiers	Doctrine ORM avec Collection et CollectionElement	PARTIEL
Erreurs	die(), FALSE, suppressions avec @	Exceptions et InvalidArgumentException dans les services	PARTIEL
Construction	Pseudo-constructeurs portant le nom de la classe	__construct() et services.xml Symfony	PORTÉ
Tests	Legacy/test.php, script d'exemple minimal	46 classes PHPUnit, mocks et fixtures locales	PORTÉ

La décomposition du modèle seq

La classe Legacy/seq.php : : seq mélangeait identité, métadonnées GenBank/Swiss-Prot, séquence brute, références et opérations. La refonte sépare ces responsabilités :

Responsabilité	Avant	Après
Séquence commune	id, longueur, type moléculaire, source, séquence, description, organisme, start/end	Domain\Sequence\Entity\Sequence
Champs GenBank	brins, topologie, division, segment, version, GI NCBI	Domain\Sequence\Entity\GbSequence
Relations documentaires	accessions, auteurs, références, mots-clés, features	Accession, Author, Reference, Keyword, Feature
Champs Swiss-Prot	références de banques et source de formulaire	SpDatabank, SrcForm
Objet protéine	id, nom, séquence	Domain\Sequence\Entity\Protein
Comportements	calculs et recherches portés par seq	SequenceBuilder + SequenceManager + ProteinManager

Bénéfice principal

Le modèle de données devient persistant et les opérations deviennent testables isolément. En contrepartie, une opération simple peut maintenant nécessiter plusieurs dépendances injectées.

3. Séquences et protéines

Le portage de Legacy/seq.php est le plus complet du dépôt. Les noms passent du snake_case au camelCase et l'objet d'état est séparé du service de calcul.

Ancienne fonction	Successeur	Écart / note	Statut
complement	SequenceBuilder::complement -> SequenceManager::complement	Complément DNA/RNA ; tables fournies par NucleotidApi.	PORTÉ
revcomp	SequenceTrait::revCompDNA	Complément inverse DNA disponible comme méthode de trait, absent de SequenceInterface et sans variante RNA publique.	PARTIEL
halfstr	SequenceBuilder::halfSequence	Même séparation des deux moitiés, pont central ignoré pour une longueur impaire.	PORTÉ
get_bridge	SequenceBuilder::getBridge	Extraction du nucléotide central d'une chaîne impaire.	PORTÉ
expand_na	SequenceBuilder::expandNa	Expansion des symboles IUPAC en expressions régulières.	PORTÉ
seq::molwt	SequenceBuilder/SequenceManager::molwt	Calcul DNA/RNA ; poids nucléotidiques et eau externalisés vers les API.	PARTIEL
protein::molwt	ProteinManager::molwt	Calcul protéique conservé ; poids des acides aminés fournis par AminoApi.	PORTÉ
protein::seqlen	ProteinManager::seqlen	Longueur calculée à partir de Protein::getSequence().	PORTÉ
count_codons	SequenceBuilder::countCodons	Utilise toujours CDS /codon_start et une longueur de séquence.	PORTÉ
subseq + trunc	SequenceBuilder::subSeq	Le remplacement renvoie une chaîne ; subseq renvoyait un nouvel objet seq. trunc n'a plus d'entrée distincte.	PARTIEL
seq::seqlen	Sequence::getSeqLength	La longueur est stockée dans l'entité et non systématiquement recalculée par strlen().	PARTIEL
symfreq	SequenceBuilder::symFreq	Fréquence d'un symbole, zéro si absent.	PORTÉ

3. Séquences et protéines - suite

Ancienne fonction	Successeur	Écart / note	Statut
patpos	SequenceBuilder::patPos	Positions sans chevauchement.	PORTÉ
patposo	SequenceBuilder::patPoso	Positions avec chevauchement et pas de reprise cut position.	PORTÉ
patfreq	SequenceBuilder::patFreq	Comptage des motifs reconnus.	PORTÉ
findpattern	SequenceBuilder::findPattern	Recherche regex après expansion IUPAC.	PORTÉ
getcodon	SequenceBuilder::getCodon	Index de codon à base zéro et reading frame.	PORTÉ
translate	SequenceBuilder::translate	Traduction complète en alphabet 1 ou 3 lettres.	PORTÉ
translate_codon	SequenceBuilder::translateCodon	Table de traduction encore implémentée dans le service.	PORTÉ
charge	SequenceBuilder::charge	Réduction en A/C/N, avec exception sur symbole invalide.	PORTÉ
chemgrp	SequenceBuilder::chemicalGroup	Réduction en groupes chimiques A/L/M/R/C/H/I/S.	PORTÉ
is_mirror / find_mirror	SequenceBuilder::isMirror / findMirror	Miroirs et positions, options pair/impair/tous.	PORTÉ
is_palindrome / find_palindrome	SequenceBuilder::isPalindrome / findPalindrome	Palindromes biologiques par complément inverse DNA.	PORTÉ

Nouvelle chaîne d'appel

Le consommateur configure un `Sequence` dans `SequenceBuilder`. Le builder fournit les valeurs par défaut puis délègue à `SequenceManager`. Les alphabets, compléments et masses sont obtenus via `AminoApiAdapter`, `NucleotidApiAdapter` et `ElementApiAdapter`.

Point de vigilance

`SequenceBuilder::molwt()` doit être revu avant de garantir l'équivalence : dans l'état analysé, le builder transmet le type moléculaire comme premier argument du manager, alors que ce premier argument représente la limite upperlimit/lowerlimit.

4. Alignements, comparaison et utilitaires

Alignements FASTA et CLUSTAL

Legacy/seqalign.php	SequenceAlignmentManager	Note	Statut
SeqAlign(filename, format)	setFilename + setFormat + parseFile	Le constructeur n'effectue plus d'I/O ; parseFasta/parseClustal sont explicites.	PORTÉ
sort_alpha	sortAlpha	Tri ascendant ou descendant.	PORTÉ
first/last/prev/next	ArrayIterator interne	Méthodes supprimées. getSeqSet() renvoie une copie tableau ; pas de façade publique équivalente de curseur.	PARTIEL
fetch(index)	getSeqSet()[index]	Accès indirect par le tableau retourné.	PARTIEL
get_length	getMaxLength	Longueur maximale de l'ensemble.	PORTÉ
get_gap_count	getGapCount	Nombre total de tirets dans l'alignement.	PORTÉ
get_is_flush	getIsFlush	Vérifie l'égalité des longueurs.	PORTÉ
char_at_res	charAtRes	Caractère à un numéro de résidu, en tenant compte des gaps.	PORTÉ
substr_bw_res	substrBwRes	Sous-chaîne entre deux résidus.	PORTÉ
col2res / res2col	colToRes / resToCol	Conversions colonnes/résidus.	PORTÉ
subalign / select	subalign / select	Sous-ensembles consécutifs ou sélection d'indices.	PORTÉ
res_var / consensus	resVar / consensus	Positions variables et consensus selon seuil.	PORTÉ
add_seq / del_seq	addSequence / deleteSequence	Manipulation d'objets Sequence typés.	PORTÉ

Comparaison de séquences

Legacy/etc.php	Successeur	Note	Statut
class submatrix	Domain\Sequence\Entity\SubMatrix	Règles privées avec getRules() et addrule().	PORTÉ
compare_letter	SequenceMatchManager::compareLetter	Exact, partiel ou non-match.	PORTÉ
partial_match	SequenceMatchManager::partialMatch	Appartenance commune à une règle.	PORTÉ
hamdist	SequenceMatchManager::hamdist	N'accepte plus directement un ancien objet seq ; chaînes typées.	PARTIEL
levdist / xlevdist	SequenceMatchManager::levdist / xlevdist	Limites 255/1024 et coûts conservés.	PORTÉ
match	SequenceMatchManager::match	Renvoie le motif de comparaison ; matrice injectable.	PORTÉ

Utilitaires Legacy/etc.php

Ancien helper	Remplacement	Note	Statut
left, right	FormatsTrait::left, right	Helpers de sous-chaîne.	PORTÉ
trim_element, rem_right, intrim	FormatsTrait	Nettoyage et retrait de caractères/espaces.	PORTÉ
getmin	FormatsTrait::getmin	Minimum de trois valeurs, utilisé par la distance étendue.	PORTÉ
is_even, is_odd	Tests modulo dans SequenceManager	Logique intégrée, plus d'API utilitaire.	PARTIEL
is_false	Tests stricts/isset dans le code	Pas de méthode dédiée.	PARTIEL
is_blankstr, is_blank	Comparaisons null/chaîne/0	Pas de méthode dédiée ; contrats désormais plus typés.	PARTIEL
firstchar	substr ou FormatsTrait::left	Fonction globale supprimée.	PARTIEL
getpattern + patterndb	Motifs passés directement	La petite base _StartCodon/_EndCodon n'a pas de composant public dédié.	PARTIEL

Outils ajoutés par la refonte

- GeneticsFunctions : comptage A/C/G/T et symboles ambigus, inversion, nettoyage protéique.
- MathematicsFunctions : moyenne, médiane et variance.
- OligosManager : génération d'oligonucléotides de 2 à 8 bases, recherche et Z-score.

Statut de ces outils

Ils sont des ajouts structurants plutôt que des remplacements directs de fonctions identifiables dans Legacy/. OligosManager est câblé comme service et possède une suite de tests dédiée.

5. Enzymes de restriction

Legacy/resten.php est repris presque méthode pour méthode, mais la base d'enzymes n'est plus un tableau global de plusieurs centaines d'entrées : elle provient de l'API BioPHP.

Legacy	Refonte	Écart / note	Statut
class RestEn	Entity\Enzyme + RestrictionEnzymeManager	L'état et les comportements sont séparés.	PORTÉ
parse_args	Arguments typés de parseEnzyme	La mini-syntaxe BioPerl sous forme de chaîne est supprimée.	PARTIEL
RestEn(args)	RestrictionEnzymeManager::parseEnzyme	Création custom ou résolution d'une enzyme connue.	PORTÉ
CutSeq	cutSeq	Modes N sans chevauchement et O avec chevauchement conservés.	PORTÉ
GetPattern	getPattern	Lecture du motif de reconnaissance.	PORTÉ
GetCutPos	getCutPos	Lecture de la position de coupure.	PORTÉ
GetLength	getLength	Longueur du motif.	PORTÉ
FindRestEn	findRestEn	Recherche par motif, coupure, longueur et combinaisons.	PORTÉ
\$RestEn_DB	TypeIIEndonucleaseApi + DTO	Donnée distante ; disponibilité et version dépendent de l'API.	PARTIEL

Extension du domaine

La refonte ajoute des adaptateurs et DTO distincts pour les endonucléases de type II, IIB et IIS, ainsi que les fournisseurs et leurs liens. Ces modèles enrichissent le vieux RestEn sans provenir d'une classe Legacy équivalente.

Impact opérationnel

Le constructeur de RestrictionEnzymeManager charge les enzymes depuis l'adaptateur. Une utilisation hors ligne doit donc injecter un double de test ou un adaptateur local ; l'ancien tableau global fonctionnait sans réseau.

6. Bases locales, GenBank et Swiss-Prot

Legacy/seqdb.php est remplacé par un ensemble plus explicite : DatabaseManager orchestre, les factories choisissent le format, les parseurs construisent des entités et Doctrine mémorise les collections.

Legacy/seqdb.php	Successeur	Écart / note	Statut
SeqDB()	DatabaseManager::__construct + recording	Le pseudo-constructeur et les fichiers d'index deviennent un service et des lignes Doctrine.	PARTIEL
at_entrystart	DatabaseRecorderFactory::getEntryStart	Détection LOCUS GenBank ou ID Swiss-Prot.	PORTÉ
get_entryid	DatabaseRecorderFactory::getEntryId	Extraction de l'identifiant selon le format.	PORTÉ
line2r	DatabaseManager::line2r	Lecture d'un enregistrement jusqu'à //.	PORTÉ
fetch	DatabaseManager::fetch(seqId)	Recherche CollectionElement puis lecture et dispatch du parseur.	PORTÉ
parse_id	ParseGenbankManager::parseDataFile	Métadonnées, références, organisme, accessions, features et séquence.	PORTÉ
parse_swissprot	ParseSwissprotManager::parseDataFile	ID, AC, DT, DE, KW, OS/OC, FT, DR, références, GN et SQ.	PORTÉ
process_ft	buildFTField / parseFeatures	Décodage des features déplacé dans les parseurs spécialisés.	PORTÉ
first/last/prev/next	Aucun équivalent public	La navigation par pointeur de base est abandonnée au profit de fetch par identifiant.	NON PORTÉ
open/close	Cycle de vie Doctrine et fichiers locaux	Plus d'API explicite d'ouverture/fermeture d'index .idx/.dir.	PARTIEL
fseekline/bsrch_tabfile	Repository Doctrine	La recherche binaire dans les index plats disparaît.	PARTIEL

Formats effectivement supportés

GENBANK	SWISSPROT	AUTRES FORMATS
ParseGenbankManager + tests sur data/human.seq	ParseSwissprotManager + tests sur data/basicswiss.txt	DatabaseReaderFactory lève Unknown database format.

Cas de Legacy/entrez.inc.php

parse_genome_entrez et ses parseurs de références recouvrent conceptuellement une partie du lecteur GenBank moderne. Toutefois, la forme Genome_Entrez et la fonction de conversion r2oGenome_Entrez ne sont pas conservées. Le remplacement est donc **partiel**, via ParseGenbankManager et les entités de séquence.

7. Parseurs spécialisés non portés

Les fichiers ci-dessous contiennent de vraies capacités métier historiques, mais aucune factory, entité ou service correspondant n'existe dans la refonte. Les entités génériques de séquence ne suffisent pas à préserver leurs champs spécifiques.

Fichier	Ancienne API	Fonction	État dans la refonte	Statut
aaindex.inc.php	AAIndex / parse_amino_aaindex	Index physico-chimiques d'acides aminés.	AminoApi fournit des référentiels, pas un parseur AAIndex.	NON PORTÉ
blocks.inc.php	ProtFam_Blocks / parse_protfam_blocks	Familles protéiques BLOCKS.	Aucun modèle de famille protéique.	NON PORTÉ
embl.inc.php	EmblSeq / parse_na_embl	Enregistrements nucléotidiques EMBL.	La factory moderne ne reconnaît pas EMBL.	NON PORTÉ
epd.inc.php	Promoter / parse_promoter_epd	Promoteurs EPD.	Aucun modèle Promoter.	NON PORTÉ
expasy.inc.php	Enzyme_Expasy / parse_enzyme_expasy	Fiches enzymatiques Expasy.	Enzyme moderne = restriction, sémantique différente.	NON PORTÉ
genome.inc.php	genome / parse_genome_dogs	Génomes au format DOGS, lecture multi-fichiers.	Aucun lecteur DOGS.	NON PORTÉ
hgbase.inc.php	Mutation / parse_mutation_hgbase	Mutations HGBASE.	Aucun modèle Mutation.	NON PORTÉ
lit.inc.php	Lit, Journal / parse_journal_ncbilit	Références NCBI Literature et lots.	Reference couvre des citations de séquence, pas ce parseur.	NON PORTÉ
motif.inc.php	Motif / parse_motif_prosite	Motifs PROSITE.	La recherche de motifs existe, le format PROSITE non.	NON PORTÉ
pdb.inc.php	Protein_PDB / parse_protein_pdb	Métadonnées et structure PDB.	Protein ne modélise que id/nom/séquence.	NON PORTÉ
pdbstr.inc.php	Protein_PDBSTR / parse_protein_pdbstr	Structure protéique PDBSTR.	Aucun modèle structural.	NON PORTÉ

7. Parseurs spécialisés non portés - suite

Fichier	Ancienne API	Fonction	État dans la refonte	Statut
pir.inc.php	PIRSeq / parse_protein_pir_codata	Protéines PIR CODATA, option SQL.	Aucun lecteur PIR.	NON PORTÉ
pmd.inc.php	Protein_PMD / parse_protein_pmd	Protéines PMD.	Aucun lecteur PMD.	NON PORTÉ
prf.inc.php	Protein_PRF / parse_protein_prf	Protéines PRF.	Aucun lecteur PRF.	NON PORTÉ
prints.inc.php	PrintsMotif / parse_motif_prints	Motifs PRINTS.	Aucun lecteur PRINTS.	NON PORTÉ
prodom.inc.php	ProtFam_Prodom / parse_protfam_prodom	Familles protéiques ProDom.	Aucun modèle de domaine/famille.	NON PORTÉ
transfac.inc.php	TFMatrix, TFGene, TFClass, Cell, Factor, Site	Six parseurs TRANSFAC.	Aucun modèle de facteur de transcription.	NON PORTÉ
unigene.inc.php	Gene_Unigene / parse_gene_unigene	Clusters de gènes UniGene.	Aucun modèle Gene.	NON PORTÉ
kegg.inc.php	Compound, Enzyme, Reaction, Ortholog, Genome, ECRel	KEGG : génomes, orthologues, composés, enzymes, réactions, relations EC, écriture de réactions.	Aucun domaine KEGG ; les stubs Ligand/Mol étaient déjà incomplets.	NON PORTÉ

Fichiers Legacy à statut particulier

Fichier	Rôle ancien	Remplacement	Statut
refseq.inc.php	Copie autonome du constructeur SeqAlign pour FASTA/CLUSTAL.	SequenceAlignmentManager::parseFasta/parseClustal	PORTÉ
test.php	Script manuel créant un seqdb sur human.seq.	Suites PHPUnit et fixtures data/	PARTIEL

Conséquence produit

La refonte actuelle ne doit pas être présentée comme une compatibilité fonctionnelle complète avec BioPHP Legacy. Elle constitue un noyau modernisé et testé, avec un périmètre de formats nettement réduit.

8. Données externalisées et nouvelles API

Une partie de la refonte ne remplace pas un algorithme, mais le lieu où vivent les données. Le code historique embarquait des tables ; le bundle interroge une API REST/Hydra et transforme les réponses en DTO.

Donnée	Avant	Après	Usage / statut
Compléments et masses DNA/RNA	Tableaux dans Legacy/seq.php	NucleotidApi + NucleotidDTO	Utilisé par SequenceManager et OligosManager
Masses d'acides aminés	Tableau dans protein::molwt	AminoApi + AminoDTO	Utilisé par ProteinManager
Masse de l'eau / éléments	Constante 18.015	ElementApi + ElementDTO	SequenceManager charge l'élément id 6
Enzymes de restriction	\$RestEn_DB dans resten.php	TypeIIEndonucleaseApi + DTO	Utilisé par RestrictionEnzymeManager
Matrice PAM250	Matrice fournie/globalement attendue	Pam250MatrixDigitApi	Disponible ; pas directement câblée à SequenceMatchManager
Codons et espèces	Traduction codée dans seq.php	TripletApi + TripletSpecieApi	API ajoutée ; translateCodon reste codé dans le manager
pK et empilement de bases	Pas de module Legacy direct identifié	PKApi + TmBaseStackingApi	AJOUT
Réductions protéiques	chemgrp/charge seulement	ProteinReductionApi	AJOUT plus générique
Fournisseurs et liens	Absent	VendorApi + VendorLinkApi	AJOUT
Endonucléases Iib et IIs	RestEn générique	TypeIibEndonucleaseApi + TypeIisEndonucleaseApi	AJOUT spécialisé

Contrat technique des API

- Les clients héritent de `Bioapi` et reçoivent Guzzle, JMS Serializer et éventuellement une clé API.
- Les collections Hydra sont lues depuis `hydra:member` puis converties en DTO.
- Chaque famille expose un adapter interface et un alias dans `Api/Resources/config/services.xml`.
- Les tests remplacent les clients/adaptateurs et chargent des tableaux depuis `Tests/**/samples`.

Nouveau compromis

Les données peuvent évoluer sans publier une nouvelle version de la bibliothèque, mais les services dépendent désormais de la disponibilité, de la compatibilité et du contenu de l'API distante.

9. Compatibilité et garanties

Ruptures de contrat à prévoir

Sujet	Legacy	Refonte	Action de migration
Nommage	snake_case et noms libres	camelCase, namespaces et interfaces	Adapter les appels et imports.
Objets acceptés	Plusieurs fonctions acceptent chaîne ou objet seq	Paramètres scalar/Entity typés	Extraire la séquence ou construire l'entité.
Sous-séquence	subseq renvoie un objet seq	subSeq renvoie string	Recréer une Entity\Sequence si nécessaire.
Erreurs	die(), FALSE, parfois @	Exceptions ou FALSE selon les méthodes	Ajouter une stratégie de gestion d'exceptions.
Données	Toujours locales et codées en dur	Chargées par API au constructeur	Prévoir adaptateur local/cache et échecs réseau.
Itération	Pointeurs first/last/prev/next/fetch	Tableaux, ArrayIterator interne, fetch par id	Réécrire les boucles de navigation.
Base locale	.idx/.dir et recherche binaire	Entités Doctrine	Migrer les index vers Collection/CollectionElement.
Formats	Large catalogue de parseurs	GenBank et Swiss-Prot seulement	Conserver Legacy ou porter les formats requis.
Version PHP	Code PHP ancien avec each/ereg	PHP 7.2 / Symfony 4	La refonte reste elle-même sur une pile désormais ancienne.

Niveau de test visible

Le dépôt contient des tests dédiés aux cinq managers centraux, aux deux parseurs, aux entités, aux DTO et à la majorité des clients API. Les tests utilisent des mocks et les fichiers de data/. Cela donne une meilleure garantie de non-régression que le script Legacy/test.php, mais ne prouve pas une équivalence bit à bit avec toutes les entrées historiques.

Domaine	Preuve	Portée
Séquences	SequenceManagerTest	Recherche, traduction, poids, miroirs et palindromes.
Alignements	SequenceAlignmentManagerTest	FASTA/CLUSTAL et opérations d'alignement.
Matching	SequenceMatchManagerTest	Hamming, Levenshtein, matrice et match.
Restriction	RestrictionEnzymeManagerTest	Résolution, découpe et recherches.
Protéines	ProteinManagerTest	Longueur et masse moléculaire.
Bases	ParseGenbankManagerTest / ParseSwissprotManagerTest	Parsing sur échantillons locaux avec Doctrine mocké.
API	Tests Api et DTO	Hydratation des référentiels via fixtures.

10. Recommandations de migration

Priorité 1 - Sécuriser le noyau déjà porté

- Corriger et tester le passage de la limite dans `SequenceBuilder::molwt()`.
- Décider si `revCompDNA` doit devenir une méthode publique de `SequenceInterface` avec support DNA/RNA.
- Documenter les changements de retour de `subSeq` et la gestion des erreurs.
- Ajouter un adaptateur local ou une couche de cache pour rendre les calculs reproductibles hors ligne.

Priorité 2 - Formaliser la compatibilité

- Construire des tests de caractérisation exécutant des jeux de données identiques sur Legacy et la refonte.
- Comparer explicitement positions, conventions d'index, casse, whitespace, bornes de masses et symboles ambigus.
- Publier une table de migration des signatures publiques, avec exemples avant/après.

Priorité 3 - Choisir les formats à réintroduire

Ne pas porter mécaniquement les 18 familles de parseurs manquantes. Prioriser selon l'usage réel et créer pour chaque format : une entité ou un DTO adapté, un `Parse...Manager`, une branche dans la factory, un jeu de données minimal et des tests de caractérisation.

Lot	Formats	Raison	Estimation relative
A	EMBL	Proche du domaine Sequence et complément naturel de GenBank.	Effort moyen
B	PDB/PDBSTR	Valeur forte mais nécessite un vrai modèle structural.	Effort élevé
C	PROSITE/PRINTS/ProDom/BLOCKS	Peut constituer un domaine Motif/ProteinFamily cohérent.	Effort moyen à élevé
D	KEGG	Domaine riche : composés, réactions, enzymes, orthologues, voies.	Effort très élevé
E	TRANSFAC/HGBASE/UniGene/EPD	Domaines spécifiques ; porter uniquement avec besoin produit confirmé.	Effort variable
F	PIR/PRF/PMD/DOGS/NCBILIT/AAIn dex	Formats historiques à évaluer selon disponibilité des sources.	À qualifier

Critère de sortie proposé pour chaque portage

- Le parseur ne dépend plus de fonctions globales ni de `each()/ereg()`.
- Le modèle de sortie est documenté et typé autant que PHP 7.2 le permet.
- Les erreurs de format produisent une exception descriptive.
- Un fichier réel anonymisé et au moins un cas limite sont couverts par `PHPUnit`.
- La factory et le câblage `Symfony` sont mis à jour sans modifier les formats existants.

Annexe A. Vue fichier par fichier

Fichier Legacy	Responsabilité	Successeur principal	Conclusion
seq.php	Séquences, protéines, motifs, traduction, miroirs	Sequence/Protein entities, Builder, Managers, Traits	Majoritairement porté
seqalign.php	Alignements FASTA/CLUSTAL	SequenceAlignmentManager	Porté, curseurs retirés
refseq.inc.php	Copie du parsing d'alignement	SequenceAlignmentManager	Porté
etc.php	Helpers, SubMatrix, SeqMatch	FormatsTrait, SubMatrix, SequenceMatchManager	Majoritairement porté
resten.php	Endonucléases et découpe	Enzyme, RestrictionEnzymeManager, API type II	Porté, données distantes
seqdb.php	Index, navigation, GenBank, Swiss-Prot	DatabaseManager, factories, parseurs, Doctrine	Partiel
entrez.inc.php	Genome Entrez	ParseGenbankManager + entités	Partiel
embl.inc.php	EMBL	Aucun	Non porté
aaindex.inc.php	AAIndex	Aucun parseur	Non porté
blocks.inc.php	BLOCKS	Aucun	Non porté
epd.inc.php	EPD	Aucun	Non porté
expasy.inc.php	Enzymes Expasy	Aucun équivalent sémantique	Non porté
genome.inc.php	DOGS	Aucun	Non porté
hgbase.inc.php	HGBASE	Aucun	Non porté
kegg.inc.php	KEGG	Aucun	Non porté
lit.inc.php	NCBI Literature	Aucun parseur	Non porté
motif.inc.php	PROSITE	Recherche générique de motifs seulement	Non porté
pdb.inc.php	PDB	Aucun modèle structural	Non porté
pdbstr.inc.php	PDBSTR	Aucun	Non porté
pir.inc.php	PIR CODATA	Aucun	Non porté
pmd.inc.php	PMD	Aucun	Non porté
prf.inc.php	PRF	Aucun	Non porté
prints.inc.php	PRINTS	Aucun	Non porté
prodom.inc.php	ProDom	Aucun	Non porté
transfac.inc.php	TRANSFAC	Aucun	Non porté
unigene.inc.php	UniGene	Aucun	Non porté
test.php	Exemple manuel SeqDB	Tests PHPUnit	Remplacé conceptuellement

Résumé final

Le chemin de migration recommandé est de considérer Legacy/ comme une bibliothèque de référence : conserver temporairement les parseurs non portés, stabiliser le noyau moderne par des tests de caractérisation, puis réintroduire seulement les formats ayant une valeur produit démontrée.

Sources inspectées

Legacy/*.php ; Api/**/*.php et Api/Resources/config/services.xml ; Domain/Sequence/**/* ; Domain/Database/**/* ; Domain/Tools/**/* ; DependencyInjection/* ; Tests/**/* ; composer.json ; phpunit.xml ; README.md. Analyse sans source externe.